

Uvod v numerične metode

Ruslan Urazbakhtin

23. februar 2026

Kazalo

| | | |
|----------|---|-----------|
| 1 | Uvod | 3 |
| 1.1 | Absolutna in relativna napaka | 3 |
| 1.2 | Predstavljiva števila | 3 |
| 1.3 | Vrste napak pri numeričnem računanju | 4 |
| 1.4 | Občutljivost problema | 5 |
| 1.5 | Stabilnost numerične metode | 6 |
| 1.6 | Analiza zaokrožitvenih napak | 6 |
| 2 | Nelinearne enačbe | 7 |
| 2.1 | Uvod | 7 |
| 2.2 | Bisekcija | 7 |
| 2.3 | Navadna iteracija | 8 |
| 2.4 | Tangentna metoda | 10 |
| 2.5 | Metode brez računanja odvoda | 11 |
| 2.6 | Ničle polinomov | 12 |
| 3 | Sistemi linearnih enačb | 14 |
| 3.1 | Uvod | 14 |
| 3.2 | Vektorske in matrične norme | 16 |
| 3.3 | Občutljivost sistemov linearnih enačb | 19 |
| 3.4 | LU razcep | 20 |
| 3.5 | Analiza zaokrožitvenih napak pri LU razcepu | 24 |
| 3.6 | Sistemi posebne oblike | 24 |
| 4 | Sistemi nelinearnih enačb | 25 |
| 4.1 | Newtonova metoda | 25 |
| 4.2 | Kvazi Newtonove metode | 26 |
| 5 | Linearni problemi najmanjših kvadratov | 28 |
| 5.1 | Uvod | 28 |
| 5.2 | QR razcep | 28 |
| 5.3 | Givensove rotacije | 29 |
| 5.4 | Householderjeva zrcaljenja | 31 |
| 6 | Problemi lastnih vrednosti | 32 |
| 6.1 | Potenčna metoda | 32 |
| 6.2 | Inverzna iteracija | 34 |
| 6.3 | Ortogonalna iteracija | 34 |
| 6.4 | QR iteracija | 35 |
| | 6.4.1 Redukcija na Hessenbergovo obliko | 35 |
| | 6.4.2 Premiki | 36 |
| 7 | Polinomska interpolacija | 38 |
| 7.1 | Uvod | 38 |
| 7.2 | Lagrangeva interpolacija | 38 |
| 7.3 | Deljene difference | 39 |

1 Uvod

Numerična metoda je postopek, ki iz danih numeričnih podatkov s končnim številom elementarnih operacij: $+$, $-$, $/$, $*$, $\sqrt{}$, izračuna numerični rezultat.

Numerična metoda je *direktna*, če s točnim računanjem izračuna točno rešitev s končnim številom osnovnih operacij. Druga možnost so *iterativne metode*, kjer je rešitev limita nekega konvergentnega zaporedja.

1.1 Absolutna in relativna napaka

Definicija 1.1. *Napaka približka* je razlika med približkom \hat{x} in točno vrednostjo x .

- *Absolutna napaka* je $d_a = \hat{x} - x$.
- *Relativna napaka* je $d_r = \frac{\hat{x} - x}{x}$.

1.2 Predstavljiva števila

V računalniku so *predstavljiva* števila zapisana v premični piki kot

$$x = \pm m \cdot b^e,$$

kjer je $m = 0.c_1c_2 \dots c_t$ *mantisa* in

- b : *baza* (običajno 2 ali 10),
- t : *dolžina mantise*,
- e : *eksponent* v mejah $L \leq e \leq U$,
- c_i : *števke* v mejah od 0 do $b - 1$.

Če je $c_1 \neq 0$, potem je število *normalizirano*, sicer pa *subnormalizirano*. Zahtevamo, da lahko $c_1 = 0$, samo če $e = L$. Množico vseh predstavljenih števil označimo s $P(b, t, L, U)$.

Zgled 1.2. Naj bo $x \in P(b, t, L, U)$. Tedaj

$$x = \pm(c_1b^{-1} + c_2b^{-2} + \dots + c_tb^{-t}) \cdot b^e.$$

Na primer

$$0.1101_2 \cdot 2^2 = (2^{-1} + 2^{-2} + 2^{-4}) \cdot 2^2 = 3.25.$$

Standard IEEE

- *single*: $P(2, 24, -125, 128)$.
- *double*: $P(2, 53, -1021, 1023)$.

Zaokrožanje

Naj bo x pozitivno število z neskončnim zapisom

$$x = 0.d_1d_2 \dots d_td_{t+1} \dots \cdot b^e.$$

Kandidata za predstavljen približek, ki ga označimo s $\text{fl}(x)$, sta najbližji predstavljeni števili z leve in z desne

$$\begin{aligned} x_- &= 0.d_1d_2 \dots d_t \cdot b^e, \\ x_+ &= (0.d_1d_2 \dots d_t + b^{-t}) \cdot b^e. \end{aligned}$$

Pri standardu IEEE uporabimo *zaokrožanje* in za $\text{fl}(x)$ izberemo predstavljivo število, ki je najbližje x . Če pa x ravno na sredine, vzamemo tisto število, ki ima sodo zadnjo števko.

Osnovna zaokrožitvena napaka

Izrek 1.3. Če za število x velja, da $|x|$ leži na intervalu med najmanjšim in največjim pozitivnim predstavljivim normaliziranim številom, potem velja

$$\frac{|\text{fl}(x) - x|}{|x|} \leq u,$$

kjer je $u = \frac{1}{2}b^{1-t}$ osnovna zaokrožitvena napaka.

Dokaz. Zapišemo število x v obliki

$$x = 0.d_1 \dots d_t + 0.0 \dots 0d_{t+1}d_{t+2} \dots$$

in število $\text{fl}(x)$ v premični piki. Ocenimo napako pri zaokroževanju navzdol in navzgor. \square

Velja

$$\text{fl}(x) = x(1 + \delta) \text{ za } |\delta| \leq u$$

- single: $u = 2^{-24} \approx 6 \cdot 10^{-8}$,
- double: $u = 2^{-53} \approx 1 \cdot 10^{-16}$.

Računanje po standardu IEEE

Velja *pravilo korektnega zaokroževanja*: Če na dveh predstavljivih številih izvedemo osnovno računsko operacijo in je rezultat spet v intervalu predstavljivih števil, dobimo isto, kot če bi zaokrožili točen rezultat.

Če sta x, y predstavljeni števili in je rezultat znotraj normaliziranih predstavljivih števil, potem velja:

- $\text{fl}(x \oplus y) = (x \oplus y)(1 + \delta)$, $|\delta| \leq u$,
- $\text{fl}(\sqrt{x}) = \sqrt{x}(1 + \delta)$, $|\delta| \leq u$.

Izjeme so:

- če pride do *prekoračitve* (overflow) obsega predstavljivih števil, dobimo $\pm\infty$,
- če pride do *podkoračitve* (underflow) obsega predstavljivih števil, dobimo 0,
- če dopuščamo subnormalizirana števila in je $\text{fl}(x \oplus y)$ subnormalizirano število, lahko $|\delta|$ naraste v najslabšem primeru do $\frac{1}{2}$.

1.3 Vrste napak pri numeričnem računanju

Imamo tri vrste napak:

- *Neodstranljiva napaka*: ker začetni podatki niso točni.
 - Namesto z x računamo s približkom \bar{x} in zato namesto $y = f(x)$ izračunamo $\bar{y} = f(\bar{x})$. Neodstranljiva napaka je

$$D_n = y - \bar{y}.$$

- Če je funkcija f odvedljiva v točki x , potem je

$$|D_n| \approx |f'(x)| |x - \bar{x}|.$$

- *Napaka metode*: ker metoda s katero računamo, ni točna.
 - Namesto f računamo vrednost funkcije g , ki jo lahko izračunamo s končnim številom operacij. Namesto $\bar{y} = f(\bar{x})$ tako izračunamo $\tilde{y} = g(\bar{x})$. Napaka metode je

$$D_m = \bar{y} - \tilde{y}.$$

- *Zaokrožitvena napaka*: ker pri vseh vmesnih izračunih zaokrožujemo.
 - Pri računanju $\tilde{y} = g(\bar{x})$ se pri vsaki računski operaciji pojavi zaokrožitvena napaka, tako da namesto \tilde{y} izračunamo \hat{y} . Zaokrožitvena napaka je

$$D_z = \tilde{y} - \hat{y}.$$

Celotna napaka je

$$D = D_n + D_m + D_z.$$

Velja

$$|D| \leq |D_n| + |D_m| + |D_z|.$$

Najbolje je, kadar so vse tri napake približno enakega velikostnega razreda.

1.4 Občutljivost problema

Če se rezultat pri majhni spremembi argumentov (motnji oz. perturbaciji) ne spremeni veliko, je problem *neobčutljiv*, sicer pa je *občutljiv*. Občutljivost je povezana s samim problemom in neodvisna od numerične metode.

Stopnja občutljivosti

Občutljivost merimo s supremumom razmerja med spremembo rezultata in spremembo podatkov, ko gre sprememba podatkov proti 0.

Zgled 1.4. Naj bo $f : \mathbb{R} \rightarrow \mathbb{R}$ odvedljiva funkcija. Zanima nas razlika med $f(x)$ in $f(x + \delta x)$, kjer je δx majhna motnja.

Velja (diferencial)

$$|f(x + \delta x) - f(x)| \approx |f'(x)| \cdot |\delta x|,$$

torej je $|f'(x)|$ *absolutna občutljivost* f v točki x .

Za oceno relativne napake dobimo

$$\frac{|f(x + \delta x) - f(x)|}{|f(x)|} \approx \frac{|f'(x)| \cdot |x|}{|f(x)|} \cdot \frac{|\delta x|}{|x|},$$


torej je $\frac{|f'(x)| \cdot |x|}{|f(x)|}$ *relativna občutljivost* f v točki x .

Zgled 1.5 (Wilkinson). TODO

1.5 Stabilnost numerične metode

Stabilnost se navezuje na numerično metodo. Glavno orodje za preverjanje stabilnosti je *analiza zaokrožitvenih napak*.

Numerična metoda iz x namesto $y = f(x)$ izračuna \hat{y} .



Metoda je *natančna*, če je za vsak x direktna napaka majhna. Torej vedno dobimo bližnji odgovor.

Če za vsak x obstaja tak $\hat{x} = x + \Delta x$ blizu x (absolutno oz. relativno), da je $f(\hat{x}) = \hat{y}$, je metoda *obratno stabilna* (absolutno oz. relativno). Obratno stabilna metoda vedno vrne točen odgovor na bližnje vprašanje.

Povezava med občutljivostjo, direktno in obratno napako

Velja

$$|\text{direktna napaka}| \leq \text{občutljivost} \cdot |\text{obratna napaka}|$$

Torej, če je metoda obratno stabilna, je direktna napaka omejena s produktom občutljivosti in nekaj majhnega.

Če je za vsak x direktna napaka omejena s produktom občutljivosti in nekaj majhnega, je metoda *direktno stabilna*. Obratno stabilna metoda je tudi direktno stabilna, obratno pa ni nujno res.

Metoda je *stabilna*, če je obratno ali direktno stabilna.

1.6 Analiza zaokrožitvenih napak

TODO

2 Nelinearne enačbe

2.1 Uvod

Iščemo rešitve (ničle) enačbe $f(x) = 0$, kjer je $f : \mathbb{R} \rightarrow \mathbb{R}$ ali $f : \mathbb{C} \rightarrow \mathbb{C}$. Lahko imamo eno ničlo, več ničel, neskončno ničel ali nič ničel.

Naj bo f zvezno odvedljiva funkcija v okolici α in $f(\alpha) = 0$.

- Če je $f'(\alpha) \neq 0$, je α *enostavna ničla*.

Opomba 2.1. Po izreku o inverzni preslikavi obstaja okolica U točke α , da v U razen α ni nobene druge ničle.

- Če je $f'(\alpha) = 0$, je α *večkratna ničla*.
 - Če je $f \in C^m$ v okolici α in $f'(\alpha) = \dots = f^{(m-1)}(\alpha) = 0$, $f^{(m)}(\alpha) \neq 0$, je α *m -kratna ničla*.

Občutljivost ničel

Naj bo x približek za ničlo α in $|f(x)| \leq \varepsilon$. Naj bo α enostavna ničla funkcije $f \in C^1$. Vemo, da je $f'(\alpha) \neq 0$. Po Lagrangeovem izreku:

$$\begin{aligned} |f(x) - f(\alpha)| &= |f'(c)| |x - \alpha| \approx |f'(\alpha)| |x - \alpha| \\ \Rightarrow |x - \alpha| &\lesssim \frac{\varepsilon}{|f'(\alpha)|} \\ \Rightarrow \frac{1}{|f'(\alpha)|} &\text{ je občutljivost ničle } \alpha. \end{aligned}$$

Po drugi strani, vemo, da je občutljivost izračuna funkcije enaka absolutne vrednosti odvoda, tj.

$$\alpha = f^{-1}(0) \Rightarrow |(f^{-1})'(0)| = \frac{1}{|f'(\alpha)|}.$$

Naj bo zdaj α dvojna ničla, torej $f(\alpha) = f'(\alpha) = 0$, $f''(\alpha) \neq 0$. Tedaj

$$\begin{aligned} f(x) &= f(\alpha) + f'(\alpha)(x - \alpha) + \frac{f''(c)}{2}(x - \alpha)^2 \\ \Rightarrow |x - \alpha| &\lesssim \sqrt{\frac{2\varepsilon}{|f''(\alpha)|}} = O(\varepsilon^{1/2}). \end{aligned}$$

Torej potrebujemo manjši ε , da dobimo dobro aproksimacijo. Podobno m -kratno ničlo lahko izračunamo le z natančnostjo $O(\varepsilon^{1/m})$.

2.2 Bisekcija

Izrek 2.2 (o bisekciji). Naj bo $f : [a, b] \rightarrow \mathbb{R}$ zvezna in $f(a) \cdot f(b) < 0$. Tedaj obstaja $c \in (a, b)$, da je $f(c) = 0$.

Algorithm 1: Bisekcija**Data:** $a, b \in \mathbb{R}$, $f \in C[a, b]$, $\varepsilon \in (0, \infty)$ **Result:** $c \in (a, b)$, da je $f(c) \approx 0$ $e \leftarrow b - a$ **while** $e > \varepsilon$ /* $b - a > \varepsilon$ */**do** $e \leftarrow e/2$ $c \leftarrow a + e$ **if** $\text{sgn}(f(a)) = \text{sgn}(f(c))$ **then**| $a \leftarrow c$ **else**| $b \leftarrow c$ **end****end****Opomba 2.3.** TODO

- Ne preverjamo, če je $f(c) = 0$, saj je to zelo redek dogodek.
- Uporabljamo $e = e/2$ namesto $c = (a + b)/2$, da smo gotovi, da se postopek ustavi.

Opomba 2.4.

- S bisekcijo ne moremo računati ničel sode večkratnosti ali kompleksnih ničel.
- Bisekcijo lahko uporabimo za računanje polov lihe stopnje.

Analiza števila korakov. Program se ustavi, ko

$$(b - a) \cdot 2^{-k} < \varepsilon.$$

Sledi, da

$$k = \left\lceil \log_2 \left(\frac{b - a}{\varepsilon} \right) \right\rceil.$$

Torej je število korakov odvisno le od ε in začetne širine intervala.

Opazimo, da se napaka v vsakem koraku razpolovi, kar je tipičen primer linearne konvergence.

2.3 Navadna iteracijaIščemo rešitve enačbe $f(x) = 0$. Enačbo predelamo v ekvivalentno obliko $g(x) = x$, tj.

$$f(x) = 0 \text{ (} x \text{ je ničla } f) \Leftrightarrow x = g(x) \text{ (} x \text{ je negibna točka } g).$$

Zgled 2.5. Naj bo $f : D \subseteq \mathbb{R} \rightarrow \mathbb{R}$ funkcija. Lahko definiramo

- $g(x) := f(x) - x$.
- $g(x) := x - c \cdot f(x)$, $c \neq 0$.
- $g(x) := x - h(x) \cdot f(x)$, $h(x) \neq 0$.

Postopek. Izberimo začetni približek x_0 in računamo

$$x_{r+1} = g(x_r), \quad r = 0, 1, \dots$$

To je *navadna iteracija* in g je *iteracijska funkcija*.

Ob ustrezno izbrani iteracijske funkcije g in dobrem začetnem približku je $\lim_{r \rightarrow \infty} x_r = \alpha$, kjer je

$$\alpha = g(\alpha) \quad \text{oz.} \quad f(\alpha) = 0.$$

Da navadna iteracija deluje za ničlo α , mora biti g skrčitev na neki okolici α , tj.

$$|g(x) - g(y)| \leq m|x - y|, \quad m < 1.$$

Izrek 2.6. Naj bo $\alpha = g(\alpha)$ in naj bo α na $I = [\alpha - \delta, \alpha + \delta]$ za nek $\delta > 0$ zadošča Lipschitzovem pogoju, tj.

$$|g(x) - g(y)| \leq m|x - y| \quad \text{za } 0 \leq m < 1 \quad \text{za vse } x, y \in I.$$

Tedaj za vsak $x_0 \in I$ zaporedje $x_{r+1} = g(x_r)$ za $r = 0, 1, \dots$ konvergira k α in velja:

1. $|x_r - \alpha| \leq m^r |x_0 - \alpha|$;
2. $|x_{r+1} - \alpha| \leq \frac{m}{1-m} |x_{r+1} - x_r|$.

Dokaz. **TODO**

□

Opomba 2.7. Ocena $|x_{r+1} - \alpha| \leq \frac{m}{1-m} |x_{r+1} - x_r|$ nam pove, kako daleč smo od negibne točke.

Posledica 2.8. Naj bo $\alpha = g(\alpha)$. Naj bo g zvezno odvedljiva v okolici α in $|g'(\alpha)| < 1$. Tedaj obstaja $\delta > 0$, da za vsak $x_0 \in I = [\alpha - \delta, \alpha + \delta]$ zaporedje $x_{r+1} = g(x_r)$ za $r = 0, 1, \dots$ konvergira k α .

Dokaz. **TODO**

□

Naj bo $\alpha = g(\alpha)$. Naj bo g zvezno odvedljiva v okolici α in $|g'(\alpha)| < 1$:

- Če je $|g'(\alpha)| < 1$, potem je α *privlačna* negibna točka.
- Če je $|g'(\alpha)| > 1$, potem je α *odbojna* negibna točka.

Definicija 2.9. Recimo, da je $\alpha = \lim_{r \rightarrow \infty} x_r$ in obstaja

$$\lim_{r \rightarrow \infty} \frac{|x_{r+1} - \alpha|}{|x_r - \alpha|^p} = c > 0.$$

Tedaj zaporedje x_r konvergira k α z redom p .

- Če je $p = 1$, konvergenca *linearna*,
- Če je $p = 2$, konvergenca *kvadratična*,
- Če je $p = 3$, konvergenca *kubična*,
- Če je $1 < p < 2$, konvergenca *superlinearna*,
- Če je $2 < p < 3$, konvergenca *superkvadratična*.

Izrek 2.10. Naj bo $\alpha = g(\alpha)$. Naj bo g p -krat zvezno odvedljiva funkcija v okolici α in

$$g'(\alpha) = \dots = g^{(p-1)}(\alpha) = 0 \quad \text{in} \quad g^{(p)}(\alpha) \neq 0.$$

Tedaj je v bližini α red konvergence $x_{r+1} = g(x_r)$ enak p .

V primeru $p = 1$, mora veljati še, da je $|g'(\alpha)| < 1$.

Dokaz. **TODO**

□

Praktičen način.

- Pri linearni konvergenci se število točnih decimalk povečuje linearno (ni nujno za celo število).
- Pri kvadratni konvergenci se število točnih decimalk iz koraka v korak približno podvoji.

2.4 Tangentna metoda

Naj bo f dvakrat zvezna odvedljiva funkcija v okolici α in $f(\alpha) = 0$. Naj bo x_r približek za ničlo α . Iščemo popravek Δx_r , da bo $f(x_r + \Delta x_r) = 0$.

Ideja. Razvijemo $f(x_r + \Delta x_r)$ v Taylorjevo vrsto:

$$0 = f(x_r + \Delta x_r) = f(x_r) + f'(x_r) \cdot \Delta x_r + \underbrace{\frac{f''(c_r)}{2} \cdot \Delta x_r^2}_{\text{zanemarimo}}$$

$$\Rightarrow \Delta x_r \approx -\frac{f(x_r)}{f'(x_r)}.$$

Za novi približek vzamemo

$$x_{r+1} = x_r - \frac{f(x_r)}{f'(x_r)}.$$

To je *tangentna metoda*.

Opomba 2.11. Tangentna metoda je poseben primer navadne iteracije za

$$g(x) = x - \frac{f(x)}{f'(x)}.$$

Geometrijska interpretacija

TODO

Analiza reda konvergence

TODO

Konvergenca tangentne metode

Definiramo z $e_r := x_r - \alpha$ napako i -tega približka. Naj bo $f \in C^2$ in α enostavna ničla. Teda

$$0 = f(\alpha) = f(x_r) + f'(x_r)(\alpha - x_r) + \frac{f''(c_r)}{2}(\alpha - x_r)^2$$

$$\Rightarrow 0 = \frac{f(x_r)}{f'(x_r)} + \alpha - x_r + \frac{f''(c_r)}{2f'(x_r)}(\alpha - x_r)^2$$

$$\Rightarrow e_{r+1} = \frac{f''(c_r)}{2f'(x_r)}e_r^2.$$

V bližini α torej velja:

$$e_{r+1} \approx C e_r^2, \quad C = \frac{f''(\alpha)}{2f'(\alpha)}.$$

Torej za dvakrat zvezno odvedljivo funkcijo f imamo zagotovljeno lokalno konvergenco tangentne metode.

V določenih primerih imamo tudi globalno konvergenco.

Izrek 2.12. *Naj bo f na $I = [a, \infty)$ dvakrat zvezno odvedljiva funkcija, ki ima ničlo $\alpha \in I$. Naj bo f naraščajoča in konveksna. Tedaj je α edina ničla na I in za vsak $x_0 \in I$ tangentna metoda konvergira k α .*

Dokaz. **TODO**

□

2.5 Metode brez računanja odvoda

Sekantna metoda

Namesto tangente uporabimo sekanto skozi $(x_r, f(x_r))$, $(x_{r-1}, f(x_{r-1}))$. To je ekvivalentno temu, da v tangentni metodi $f'(x_r)$ aproksimiramo z $\frac{f(x_r) - f(x_{r-1})}{x_r - x_{r-1}}$. Torej

$$x_{r+1} = x_r - \frac{f(x_r)(x_r - x_{r-1})}{f(x_r) - f(x_{r-1})}.$$

V vsakem koraku potrebujemo en nov izračun funkcije f , razen na začetku 2. Na začetku še potrebujemo dve začetni vrednosti x_0 , x_1 , ni pa kakšnih dodatnih omejitev, kot pri bisekciji.

Opomba 2.13. Pričakujemo, da se sekantna metoda obnaša podobno kot tangentna metoda.

Za sekantno metodo se da pokazati zvezo

$$e_{r+1} \approx C e_r e_{r-1}.$$

Sekantna metoda ima red konvergence $p \approx 1.62$, če je α enostavna ničla in $f''(\alpha) \neq 0$.

Opomba 2.14. Sekantna metoda ni primer navadne iteracije, saj je x_{r+1} odvisen od dveh prejšnjih členov: x_r in x_{r-1} .

Mullerjeva metoda

Skozi točke $(x_r, f(x_r))$, $(x_{r-1}, f(x_{r-1}))$, $(x_{r-2}, f(x_{r-2}))$ potegnemo kvadratni polinom in za naslednji približek vzamemo tisto izmed njegovih dveh ničel, ki je bližja x_r .

Potrebujemo tri začetne približke x_0, x_1, x_2 . V vsakem koraku moramo izračunati eno vrednost funkcije, razen na začetku tri.

Velja zveza

$$|e_{r+1}| \approx C \cdot |e_r| \cdot |e_{r-1}| \cdot |e_{r-2}|.$$

Mullerjeva metoda ima red konvergence $p \approx 1.84$.

Inverzna interpolacija

Zamenjamo vlogi x in y in čez točki $(f(x_r), x_r)$, $(f(x_{r-1}), x_{r-1})$, $(f(x_{r-2}), x_{r-2})$ napeljemo kvadratni polinom. Ta kvadratni polinom aproksimira inverzno funkcijo. Vzamemo

$$x_{r+1} = p(0).$$

Inverzna interpolacija ima red konvergence $p \approx 1.84$.

Kombinirane metode

Kombiniramo več metod in s tem zagotovimo robustnost, kot pri bisekciji, s hitrejšo konvergenco, kot npr. pri inverzni interpolaciji.

Imamo interval $[a, b]$, kjer je $f(a) \cdot f(b) < 0$. Naslednji potencialni približek c izračunamo npr. s sekantno metodo ali inverzno interpolacijo. Če je c izven intervala $[a, b]$ namesto tega izberemo $c = \frac{a+b}{2}$. Nadaljujemo podobno kot pri bisekciji.

Primer 2.15. Brantova metoda (fzero) kombinira bisekcijo, sekantno metodo in inverzno interpolacijo.

2.6 Ničle polinomov

Imamo polinom $p(x) = a_n x^n + a_{n-1} x^{n-1} + \dots + a_1 x + a_0$, ki ima ničle $\alpha_1, \dots, \alpha_n$. Možnosti za izračun ničel so:

1. Ničle računamo eno po eno (ali dve po dve, če imamo konjugirane pare). Če je α_1 enostavna ničla, je

$$p(x) = (x - \alpha_1)q(x), \quad \text{st } q(x) = n - 1.$$

Nadaljujemo z iskanjem ničel polinoma $q(x)$.

Primer 2.16. Laguerreova metoda, Bairstow-Hitchcode.

2. Problem prevedemo na računanje lastnih vrednosti matrike

$$C_p = \begin{bmatrix} 0 & 1 & & & \\ & 0 & 1 & & \\ & & \ddots & \ddots & \\ & & & 0 & 1 \\ -\frac{a_n}{a_0} & -\frac{a_{n-1}}{a_0} & \dots & -\frac{a_2}{a_0} & -\frac{a_1}{a_0} \end{bmatrix}$$

C_p je spremljevalna matrika polinoma $p(x)$. Njen karakteristični polinom je s skalarjem pomnožen $p(x)$. Lastne vrednosti C_p so ničle $p(x)$.

Primer 2.17. Funkcija `roots` v MatLab.

3. Metode, ki vzporedno računajo vse ničle polinoma.

Primer 2.18. Ehrlich-Abertborva metoda, Durand-Kernerjeva metoda.

Primer 2.19 (Durand-Kernerjeva metoda). Naj bo p polinom stopnje n z vodilnim koeficientom 1. Potem ima p ničle $\alpha_1, \dots, \alpha_n$ in je $p(x) = (x - \alpha_1) \cdots (x - \alpha_n)$.

Naj bo x_1, \dots, x_n paroma različni približki za $\alpha_1, \dots, \alpha_n$. Iščemo popravke $\Delta x_1, \dots, \Delta x_n$, da bodo $x_1 + \Delta x_1, \dots, x_n + \Delta x_n$ točne ničle p . Tedaj

$$\begin{aligned} p(x) &= (x - (x_1 + \Delta x_1)) \cdots (x - (x_n + \Delta x_n)) \\ &= \prod_{j=1}^n (x - x_j) - \sum_{j=1}^n \Delta x_j \prod_{k=1, k \neq j}^n (x - x_k) \\ &\quad + \underbrace{\sum_{j,k=1, j < k}^n \Delta x_j \Delta x_k \prod_{l=1, l \neq j, k}^n (x - x_l) + \dots}_{\text{zanemarimo}} \end{aligned}$$

Vstavimo $x = x_i$, dobimo

$$\begin{aligned} p(x_i) &= -\Delta x_i \prod_{k=1, k \neq i}^n (x_i - x_k) \\ \Rightarrow \Delta x_i &= -\frac{p(x_i)}{\prod_{k=1, k \neq i}^n (x_i - x_k)} \end{aligned}$$

Definiramo

$$\begin{aligned} x^{(0)} &= [x_1^{(0)}, \dots, x_n^{(0)}] \\ \Rightarrow x_i^{(r+1)} &= x_i^{(r)} - \frac{p(x_i^{(r)})}{\prod_{k=1, k \neq i}^n (x_i^{(r)} - x_k^{(r)})}, \quad r = 0, 1, \dots, \quad i = 1, \dots, n. \end{aligned}$$

3 Sistemi linearnih enačb

Naj bo $\mathbb{F} \in \{\mathbb{R}, \mathbb{C}\}$.

3.1 Uvod

Rešujemo sistem linearnih enačb

$$\begin{aligned} a_{11}x_1 + \cdots + a_{1n}x_n &= b_1 \\ &\vdots \\ a_{m1}x_1 + \cdots + a_{mn}x_n &= b_m, \end{aligned}$$

ki ga pišemo v obliki

$$Ax = b,$$

kjer

$$A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix}, \quad x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}, \quad b = \begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix}.$$

Označimo z a_i i -ti stolpec matrike A in z α_j^T j -to vrstico matrike A . Naj bo

$$e_i = [0 \ \dots \ 0 \ 1_i \ 0 \ \dots \ 0]^T.$$

Tedaj velja

$$Ae_i = a_i, \quad e_j^T A = \alpha_j^T \quad \text{in} \quad e_i^T Ae_k = a_{ik}.$$

Naj bo $x, y \in \mathbb{F}^n$. Standardni skalarni produkt je

$$\langle x, y \rangle = \sum_{i=1}^n x_i \overline{y_i} = y^H x,$$

kjer je

$$A^H = \overline{A^T}$$

hermitsko transponiranje.

Če imamo sistem $y = Ax$, $A \in \mathbb{R}^{n \times n}$, $x, y \in \mathbb{R}^n$, si to lahko predstavljamo:

1. Po elementih, tj.

$$y_i = \sum_{k=1}^n a_{ik} x_k = \alpha_i^T X.$$

2. Kot linearno kombinacijo stolpcev, tj.

$$y = \sum_{i=1}^n x_i a_i \Rightarrow e_i^T y = \sum_{i=1}^n x_k e_i^T a_i.$$

Če imamo produkt $C = A \cdot B$, kjer so $A, B, C \in \mathbb{R}^n$, si to lahko predstavljamo:

1. Po elementih, tj.

$$c_{ik} = \sum_{l=1}^n a_{il}b_{lk} = \alpha_i^T b_k.$$

2. Po stolpcih, tj.

$$A \cdot [b_1 \ \dots \ b_n] = [A \cdot b_1 \ \dots \ A \cdot b_n] \Rightarrow c_i = A \cdot b_i.$$

3. Po vrsticah, tj.

$$\begin{bmatrix} \alpha_1^T \\ \vdots \\ \alpha_n^T \end{bmatrix} \cdot B = \begin{bmatrix} \alpha_1^T \cdot B \\ \vdots \\ \alpha_n^T \cdot B \end{bmatrix} \Rightarrow \gamma_i^T = \alpha_i^T \cdot B.$$

4. Kot vsoto n matrik ranga 1 (diade), tj.

$$C = \sum_{l=1}^n a_l \beta_l^T.$$

Vemo, da če $x, y \in \mathbb{R}^n$, $x, y \neq 0$, potem xy^T matrika ranga 1.

Spomnimo se nekaj osnovnih definicij in trditev. Naj bo $A \in \mathbb{F}^{n \times n}$.

Trditev 3.1. Naj bo $A \in \mathbb{F}^{n \times n}$. NTSE:

1. $A \in \mathbb{F}^{n \times n}$ je nesingularna.
2. $\exists A^{-1} \cdot A \cdot A^{-1} = A^{-1} \cdot A = I$.
3. $\det A \neq 0$.
4. $\text{rang } A = n$.
5. $\ker A = \{0\}$.
6. Vse lastne vrednosti so neničelne.

Definicija 3.2. Naj bo $A \in \mathbb{F}^{n \times n}$.

- $\lambda \in \mathbb{F}$ je lastna vrednost matrike A , če

$$\exists x \in \mathbb{F}^n \setminus \{0\} \cdot Ax = \lambda x.$$

- Matrika A je simetrična, če

$$A^T = A,$$

hermitska, če

$$A^H = A.$$

- Matrika A je simetrična pozitivno definitna, če

$$A = A^T \quad \text{in} \quad \forall x \in \mathbb{F}^n \setminus \{0\} \cdot x^T A x > 0,$$

simetrična pozitivno semidefinitna, če

$$A = A^T \quad \text{in} \quad \forall x \in \mathbb{F}^n \setminus \{0\} \cdot x^T A x \geq 0,$$

hermitska pozitivno semidefinitna, če

$$A = A^H \quad \text{in} \quad \forall x \in \mathbb{F}^n \setminus \{0\} \cdot x^H A x > 0,$$

hermitska pozitivno semidefinitna, če

$$A = A^H \quad \text{in} \quad \forall x \in \mathbb{F}^n \setminus \{0\} \cdot x^H A x \geq 0,$$

3.2 Vektorske in matrične norme

Definicija 3.3. *Vektorska norma* je preslikava $\|\cdot\| : \mathbb{C}^n \rightarrow \mathbb{R}$, za katero velja:

1. Pozitivna definitnost, tj. $\forall x \in \mathbb{C}^n. \|x\| \geq 0 \wedge \|x\| = 0 \Leftrightarrow x = 0$.
2. Homogenost, tj. $\forall \lambda \in \mathbb{C}. \forall x \in \mathbb{C}^n. \|\lambda x\| = |\lambda| \cdot \|x\|$.
3. Trikotniška neenakost, tj. $\forall x, y \in \mathbb{C}^n. \|x + y\| \leq \|x\| + \|y\|$.

Najbolj znane norme so

$$\begin{aligned}\|x\|_1 &= \sum_{i=1}^n |x_i| \\ \|x\|_2 &= \left(\sum_{i=1}^n |x_i|^2 \right)^{1/2} \\ \|x\|_\infty &= \max\{|x_i| \mid i \in \{1, \dots, n\}\}\end{aligned}$$

Vse vektorske norme so ekvivalentne, tj.

$$\forall \|\cdot\|_a, \|\cdot\|_b \in \mathbb{R}^{\mathbb{C}^n}. \forall x \in \mathbb{C}^n. \exists c_1, c_2 > 0. c_1 \|x\|_a \leq \|x\|_b \leq c_2 \|x\|_a.$$

Za $\|\cdot\|_1, \|\cdot\|_2, \|\cdot\|_\infty$ velja:

$$\begin{aligned}\|x\|_2 &\leq \|x\|_1 \leq \sqrt{n} \cdot \|x\|_2 \\ \|x\|_\infty &\leq \|x\|_2 \leq \sqrt{n} \cdot \|x\|_\infty \\ \|x\|_\infty &\leq \|x\|_1 \leq n \cdot \|x\|_\infty\end{aligned}$$

Definicija 3.4. *Matrična norma* je preslikava $\|\cdot\| : \mathbb{C}^{n \times n} \rightarrow \mathbb{R}$, za katero velja:

1. Pozitivna definitnost.
2. Homogenost.
3. Trikotniška neenakost.
4. Submultiplikativnost, tj. $\forall A, B \in \mathbb{C}^{n \times n}. \|A \cdot B\| \leq \|A\| \cdot \|B\|$.

Definicija 3.5. *Vektorizacija* matrike $A \in \mathbb{F}^{n \times n}$ je preslikava

$$\begin{aligned}\text{vec}: \mathbb{C}^{n \times n} &\rightarrow \mathbb{C}^{n^2} \\ A &\mapsto [a_{11} \ \dots \ a_{1n} \ a_{21} \ \dots \ a_{nn}]^T\end{aligned}$$

Sedaj lahko definiramo vektorske norme

$$\begin{aligned}N_1(A) &= \|\text{vec}(A)\|_1 = \sum_{i,j=1}^n |a_{ij}| \\ N_2(A) &= \|\text{vec}(A)\|_2 = \left(\sum_{i,j=1}^n |a_{ij}|^2 \right)^{1/2} \\ N_\infty(A) &= \|\text{vec}(A)\|_\infty = \max\{|x_i| \mid i \in \{1, \dots, n\}\}\end{aligned}$$

Trditev 3.6. Normi N_1 in N_2 sta matrični normi. Norma N_∞ ni matrična norma.

Dokaz. **TODO** □

Definicija 3.7. Matrična norma N_2 je *Frobeniusova norma*:

$$\|A\|_F = \left(\sum_{i,j=1}^n |a_{ij}|^2 \right)^{1/2}.$$

Lema 3.8. Naj bo $\|\cdot\|_v$ vektorska norma na \mathbb{C}^n . Tedaj je

$$\|A\|_v := \max_{x \neq 0} \frac{\|Ax\|_v}{\|x\|_v}$$

matrična norma. Rečemo ji operatorska norma.

Dokaz. **TODO** □

Sedaj lahko definiramo *operatorsko p -normo*:

$$\|A\|_p := \max_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p} \text{ za } p \in \{1, 2, \dots, \infty\}.$$

Lema 3.9. Naj bo $A \in \mathbb{C}^{n \times n}$. Tedaj

$$\|A\|_1 = \max \left\{ \sum_{i=1}^n |a_{ij}| \mid j \in \{1, \dots, n\} \right\} = \max \{ \|a_j\|_1 \mid j \in \{1, \dots, n\} \}.$$

Dokaz. **TODO** □

Lema 3.10. Naj bo $A \in \mathbb{C}^{n \times n}$. Tedaj

$$\|A\|_\infty = \max \left\{ \sum_{j=1}^n |a_{ij}| \mid i \in \{1, \dots, n\} \right\} = \max \{ \|\alpha_i^T\|_1 \mid i \in \{1, \dots, n\} \}.$$

Naj bo $A \in \mathbb{C}^{n \times n}$. Matrika $B = A^H A$ je hermitska in pozitivno semidefinitna, saj

$$1. \ B^H = (A^H A)^H = A^H (A^H)^H = A^H A = B \text{ in}$$

$$2. \ x^H B x = x^H A^H A x = (Ax)^H Ax = \|Ax\|_2^2 \geq 0.$$

Vemo, da so torej vse njene lastne vrednosti nenegativne, zato jih lahko pišemo in uredimo kot

$$\sigma_1^2 \geq \sigma_2^2 \geq \dots \geq \sigma_n^2 \geq 0.$$

Vrednostim $\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2$ pravimo *singularne vrednosti* matrike A .

Lema 3.11. Naj bo $A \in \mathbb{C}^{n \times n}$. Tedaj

$$\|A\|_2 = \sigma_1(A) = \sqrt{\lambda_{\max}(A^H A)}$$

Dokaz. **TODO** □

Definicija 3.12. Norma $\|\cdot\|$ je *spektralna norma*.

Opomba 3.13. Vsako matriko $A \in \mathbb{C}^{n \times n}$ lahko zapišemo v obliki

$$A = U \Sigma V^T,$$

kjer sta U, V ortogonalni matriki in

$$\Sigma = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix}.$$

To je *singularni razcep* matrike A .

Opomba 3.14. Frobeniusova norma ni operatorska norma, saj je $\|I\|_F = \sqrt{n}$. Za operatorske norme pa velja, da je $\|I\| = 1$.

Tudi vse matrične norme so ekvivalentne. Velja:

$$\begin{aligned} \frac{1}{\sqrt{n}} \cdot \|A\|_F &\leq \|A\|_2 \leq \|A\|_F \\ \frac{1}{\sqrt{n}} \cdot \|A\|_1 &\leq \|A\|_2 \leq \sqrt{n} \cdot \|A\|_1 \\ \frac{1}{\sqrt{n}} \cdot \|A\|_\infty &\leq \|A\|_2 \leq \sqrt{n} \cdot \|A\|_\infty \end{aligned}$$

Poleg tega velja še:

$$\begin{aligned} N_\infty(A) &\leq \|A\|_2 \leq n \cdot N_\infty(A) \\ \|A\|_2 &\leq \sqrt{\|A\|_1 \cdot \|A\|_\infty} \\ \forall i \in \{1, \dots, n\} \cdot \|a_i\|_2, \|\alpha_i^T\|_2 &\leq \|A\|_2. \end{aligned}$$

Naj bo $\|\cdot\|_m$ operatorska norma z vektorsko normo $\|\cdot\|_v$. Teda

$$\forall A \in \mathbb{C}^{n \times n} \cdot \forall x \in \mathbb{C}^n \cdot \|Ax\|_v \leq \|A\|_m \cdot \|x\|_v.$$

Definicija 3.15. Če za matrično normo $\|\cdot\|_m$ in vektorsko normo $\|\cdot\|_v$ za vsak par $A \in \mathbb{C}^{n \times n}$, $x \in \mathbb{C}^n$ velja:

$$\|Ax\|_v \leq \|A\|_m \cdot \|x\|_v,$$

pravimo, da sta normi *usklajeni*.

Lema 3.16. Za vsako matrično normo $\|\cdot\|_m$ obstaja usklajena vektorska norma $\|\cdot\|_v$.

Dokaz. **TODO** □

Lema 3.17. Naj bo $\lambda \in \mathbb{C}$ lastna vrednost matrike $A \in \mathbb{C}^{n \times n}$. Potem za poljubno matrično normo $\|\cdot\|_m$ velja:

$$|\lambda| \leq \|A\|_m.$$

Dokaz. **TODO** □

Vse norme $\|\cdot\|_1, \|\cdot\|_2, \|\cdot\|_\infty, \|\cdot\|_F$ se enostavno razširijo na pravokotne matrike $A \in \mathbb{C}^{m \times n}$. Če sta A, B ustreznih velikosti, da obstaja produkt $A \cdot B$, potem velja tudi submultiplikativnost. Ne veljajo pa vse prejšnje ocene za norme.

Velja pa

$$\begin{aligned}\|A\|_2 &= \|A^H\|_2 \\ \|A\|_F &= \|A^H\|_F \\ \|A\|_1 &= \|A^H\|_\infty\end{aligned}$$

Matrika $U \in \mathbb{C}^{n \times n}$ je *unitarna*, če $U \cdot U^H = U^H U = I$.

Lema 3.18. Normi $\|\cdot\|_2$ in $\|\cdot\|_F$ sta invariantni na množenje z unitarno matriko.

Dokaz. **TODO**

□

Lema 3.19. Naj za X velja $\|X\| < 1$. Tedaj

1. Matrika $I - X$ je obrnljiva.
2. $(I - X)^{-1} = \sum_{k=0}^{\infty} X^k$.
3. Če je $\|I\| = 1$, potem $\|(I - X)^{-1}\| \leq \frac{1}{1 - \|X\|}$.

Dokaz. **TODO**

□

3.3 Občutljivost sistemov linearnih enačb

Definicija 3.20. Naj bo $A \in \mathbb{C}^{n \times n}$. Občutljivost ali pogojnostno število matrike A je

$$\kappa(A) := \|A\| \cdot \|A^{-1}\|.$$

Opomba 3.21. Velja ocena:

$$\forall A \in \mathbb{C}^{n \times n}. \|I\| = \|A \cdot A^{-1}\| \leq \|A\| \cdot \|A^{-1}\| = \kappa(A).$$

Izrek 3.22. Naj bo $A \in \mathbb{C}^{n \times n}$ nesingularna matrika in $Ax = b$. Če A zmotimo v $A + \Delta A$ in b v $b + \Delta b$, kjer velja

$$\|\Delta A\| \leq \frac{1}{\|A^{-1}\|},$$

potem za rešitev zmotenega sistema $(A + \Delta A)(x + \Delta x) = b + \Delta b$ velja

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\kappa(A)}{1 - \kappa(A) \cdot \frac{\|\Delta A\|}{\|A\|}} \left(\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|} \right),$$

kjer za $\|\cdot\|$ velja $\|I\| = 1$.

Opomba 3.23. Velja:

$$\kappa_2(A) = \frac{\sigma_1(A)}{\sigma_n(A)}.$$

Opomba 3.24. Edine matrike z občutljivostjo 1 v $\|\cdot\|_2$ so s skalarjem pomnožene unitarne matrike.

Definicija 3.25. Hilbertova matrika $H \in \mathbb{R}^{n \times n}$ je matrika z elementi

$$h_{ij} = \frac{1}{i+j-1}.$$

Opomba 3.26. Hilbertove matrike so zelo občutljive.

TODO

3.4 LU razcep

Želimo rešiti sistem linearnih enačb

$$Ax = b, \quad A \in \mathbb{C}^{n \times n}, \quad x, b \in \mathbb{C}^n, \quad \det A \neq 0.$$

Kakšni metodi so na voljo?

Naj bo

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix}, \quad a_{11} \neq 0.$$

Definiramo

$$L_1 = \begin{bmatrix} 1 & & & \\ -l_{21} & 1 & & \\ -l_{31} & & \ddots & \\ \vdots & & & \ddots \\ -l_{n1} & & & & 1 \end{bmatrix}, \quad l_{j1} = \frac{a_{j1}}{a_{11}}, \quad j \in \{2, \dots, n\}.$$

Potem

$$L_1 A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ 0 & a_{22}^{(1)} & \dots & a_{2n}^{(1)} \\ 0 & a_{32}^{(1)} & \dots & a_{3n}^{(1)} \\ \vdots & \vdots & & \vdots \\ 0 & a_{n2}^{(1)} & \dots & a_{nn}^{(1)} \end{bmatrix}, \quad a_{22} \neq 0.$$

Nadaljujemo in dobimo

$$L_i = \begin{bmatrix} 1 & & & \\ & \ddots & & \\ & & 1 & \\ & & -l_{i+1,i} & 1 & \\ & & \vdots & & \ddots \\ & & -l_{n,i} & & & 1 \end{bmatrix}, \quad l_{ji} = \frac{a_{ji}^{(i-1)}}{a_{ii}^{(i-1)}}, \quad j \in \{i+1, \dots, n\}$$

ter

$$A^{(i-1)} = \begin{bmatrix} 0 & & & & \\ & \ddots & & & \\ & & 0 & & \\ & & & a_{ii}^{(i-1)} & \dots \\ & & & \vdots & \\ & & & a_{ni}^{(i-1)} & \dots \end{bmatrix}$$

V končnem

$$L_{n-1} \cdots L_2 L_1 A = \begin{bmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1n} \\ & a_{22}^{(1)} & a_{23}^{(1)} & \dots & a_{2n}^{(1)} \\ & & a_{33}^{(2)} & \dots & a_{3n}^{(1)} \\ & & & \ddots & \\ & & & & a_{nn}^{(n-1)} \end{bmatrix}$$

Definiramo $L_{n-1} \cdots L_2 L_1 A =: U$. Tedaj

$$A = \underbrace{L_1^{-1} L_2^{-1} \cdots L_{n-1}^{-1}}_L U = LU.$$

Kako dobimo matriko L ?

$L_j = I - l_j e_j^T$ je eliminacijska matrika

$\Rightarrow L_j^{-1} = I + l_j e_j^T$, kjer

$$l_j = [0 \ \dots \ 0 \ l_{j+1,j} \ \dots \ l_{n,j}]^T$$

$$\Rightarrow L = \begin{bmatrix} 1 & & & & \\ l_{21} & 1 & & & \\ l_{31} & l_{32} & 1 & & \\ \vdots & \vdots & & \ddots & \\ l_{n1} & l_{n2} & \dots & l_{n,n-1} & 1 \end{bmatrix}$$

S tem dobimo *LU razcep brez pivotiranja*, kjer je L spodnje trikotna z 1 na diagonali in U zgornje trikotna matrika.

Algorithm 2: LU razcep

Data: $A \in \mathbb{C}^{n \times n}$

Result: $L \in \mathbb{C}^{n \times n}$, $U \in \mathbb{C}^{n \times n}$

for $i = 1, \dots, n-1$ **do**

for $j = i+1, \dots, n$ **do**

$l_{ji} \leftarrow a_{ji}/a_{ii}$

for $k = i+1, \dots, n$ **do**

$a_{jk} \leftarrow a_{jk} - l_{ji}a_{ik}$

end

end

end

$U \leftarrow A$

Kako zdaj rešimo sistem $Ax = b$?

$$Ax = b \Leftrightarrow L \underbrace{Ux}_y = b.$$

Postopek.

1. $A = LU$,
2. Reši $Ly = b$,
3. Reši $Ux = y$.

Sistem $Ly = b$ rešimo s *premo substitucijo* (od zgoraj navzdol), tj.

$$l_{j1}y_1 + \dots + l_{j,j-1}y_{j-1} + y_j = b_j.$$

Algorithm 3: Prema substitucija

Data: $L \in \mathbb{C}^{n \times n}$, $b \in \mathbb{C}^n$

Result: $y \in \mathbb{C}^n$

for $j = 1, \dots, n$ **do**

$y_j \leftarrow b_j - \sum_{k=1}^{j-1} l_{jk}y_k$

end

Sistem $Ux = y$ rešimo s *obratno substitucijo* (od zgoraj navzdol), tj.

$$u_{jj}x_j + \dots + u_{j,n}x_n = y_j.$$

Algorithm 4: Obratna substitucija

Data: $U \in \mathbb{C}^{n \times n}$, $y \in \mathbb{C}^n$

Result: $x \in \mathbb{C}^n$

for $j = n, n-1, \dots, 1$ **do**

$x_j \leftarrow (1/u_{jj}) \cdot (y_j - \sum_{k=j+1}^n u_{jk}x_k)$

end

Elementom $a_{11}, a_{22}^{(1)}, \dots, a_{n-1,n-1}^{(n-2)}$, s katerimi delimo, pravimo *pivotni elementi*.

Izrek 3.27. Za $A \in \mathbb{C}^{n \times n}$ NTSE:

1. Obstaja enoličen LU razcep $A = LU$, kjer je L spodnje trikotna z 1 na diagonalni in U nesingularna zgornje trikotna.
2. $\det(A_k) \neq 0$ za vse $A_k = A(1:k, 1:k)$, $k \in \{1, \dots, n\}$.
3. Vse vodilne podmatrike A so nesingularne.

Zgled 3.28. Pri numeričnem računanju so težave lahko tudi zaradi pivotov, ki so sicer neničelni, a blizu 0. **TODO**

Rešitev za težave s (skoraj) ničelnimi pivoti je pivotiranje, kjer dopuščamo:

1. Menjave vrstic - *delno pivotiranje*.
2. Menjave vrstic in stolpcev - *kompletno pivotiranje*.

Delno pivotiranje

V koraku i poiščemo največjega izmed elementov $|a_{ij}|, |a_{i+1,j}|, \dots, |a_{ni}|$ in zamenjamo ustrezni vrstici.

Algorithm 5: LU razcep z delnim pivotiranjem

Data: $A \in \mathbb{C}^{n \times n}$

Result: $L \in \mathbb{C}^{n \times n}$, $U \in \mathbb{C}^{n \times n}$

```

for  $i = 1, \dots, n$  do
    find  $p \in \{i, \dots, n\}$ , da  $|a_{pi}| = \max_{l \in \{i, \dots, n\}} |a_{li}|$ 
    swap the  $i$ -th and  $p$ -th rows
    for  $j = i + 1, \dots, n$  do
         $l_{ji} \leftarrow a_{ji}/a_{ii}$ 
        for  $k = i + 1, \dots, n$  do
             $a_{jk} \leftarrow a_{jk} - l_{ji}a_{ik}$ 
        end
    end
end
end
  
```

Dobimo razcep $PA = LU$, kjer je P permutacijska matrika, ki ustreza zamenjavi vrstic. Kako zdaj rešimo sistem?

$$Ax = b \Rightarrow PAx = Pb \Rightarrow LUx = Pb$$

Postopek.

1. $PA = LU$,
2. Reši $Ly = Pb$,
3. Reši $Ux = y$.

Izrek 3.29. Če je A nesingularna, potem obstaja taka permutacijska matrika P , da za PA obstaja LU razcep brez pivotiranja.

Dokaz. **TODO**

□

Kompletno pivotiranje

Poiščemo največji element bloka in zamenjamo ustrezni vrstici in stolpca. Dobimo sistem

$$\underbrace{PAQ}_{LU} \underbrace{Q^T}_{\tilde{x}} x = Pb$$

Postopek.

1. $PAQ = LU$,
2. Reši $Ly = Pb$,
3. Reši $U\tilde{x} = y$,
4. $x = Q\tilde{x}$.

3.5 Analiza zaokrožitvenih napak pri LU razcepu

Definicija 3.30. *Pivotna rast* je

$$g(A) := \frac{\max_{i,j \in \{1, \dots, n\}} |u_{ij}|}{\max_{i,j \in \{1, \dots, n\}} |a_{ij}|}$$

TODO

3.6 Sistemi posebne oblike

Recimo, da rešujemo sistem $Ax = b$, kjer ima A posebno obliko, npr. diagonalna, trikotna itn.

Simetrična pozitivno definitna matrika

Izrek 3.31. *Naj bo $A \in \mathbb{R}^{n \times n}$. Tedaj*

1. *Če je A s.p.d., so vse vodilne podmatrike $A_k = A(1 : k, 1 : k)$ tudi s.p.d.*
2. *Če je A s.p.d., obstaja enoličen LU razcep $A = LU$, kjer je $u_{ii} > 0$ za $i \in [n]$.*
3. *A je s.p.d. natanko tedaj, ko obstaja enolična spodnja trikotna matrika V , $v_{ii} > 0$ za $i \in [n]$, da je*

$$A = V \cdot V^T.$$

To je razcep Choleskega. Matriko V pa imenujemo faktor Choleskega.

Dokaz. TODO

□

Kako rešimo sistem s pomočjo razcepa Choleskega?

Postopek.

1. $A = VV^T$,
2. $Vy = b$,
3. $V^T x = y$.

Algorithm 6: Razcep Choleskega

Data: $A \in \mathbb{C}^{n \times n}$

Result: $V \in \mathbb{C}^{n \times n}$

for $i = 1, \dots, n$ **do**

$v_{ii} \leftarrow (a_{ii} - \sum_{k=1}^{i-1} v_{ik}^2)^{1/2}$

for $j = i + 1, \dots, n$ **do**

$v_{ji} \leftarrow (1/v_{ii}) \cdot (a_{ij} - \sum_{k=1}^{i-1} v_{ik}v_{jk})$

end

end

4 Sistemi nelinearnih enačb

Naj bo $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$ oz. $F : \mathbb{C}^n \rightarrow \mathbb{C}^n$ preslikava. Iščemo vektorji $x \in \mathbb{R}^n$, ki rešijo sistem

$$F(x) = 0.$$

Podobno kot pri $n = 1$ lahko uporabimo navadno iteracijo:

1. Prepišemo enačbo $F(x) = 0$ v obliko $x = G(x)$.
2. Izberimo $x^{(0)} \in \mathbb{R}^n$.
3. Računamo rekurzivno: $x^{(r+1)} = G(x^{(r)})$.

Za konvergenco potrebujemo, da je G skrčitev na nekem zaprtem območju $\Omega \subseteq \mathbb{R}^n$, tj.

- $\forall x \in \Omega. G(x) \in \Omega$ in
- $\exists m \in [0, 1). \forall x, y \in \Omega. \|G(x) - G(y)\| \leq m \cdot \|x - y\|$.

Izrek 4.1. Naj bo $G : \mathbb{R}^n \rightarrow \mathbb{R}^n$ zvezno odvedljiva na zaprtem območju $\Omega \subseteq \mathbb{R}^n$. Recimo, da velja

- $\forall x \in \Omega. G(x) \in \Omega$ in
- $\exists m \in [0, 1). \forall x \in \Omega. \rho(J_G(x)) \leq m$,

kjer

$$J_G = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \cdots & \frac{\partial g_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial g_n}{\partial x_1} & \cdots & \frac{\partial g_n}{\partial x_n} \end{bmatrix} \text{ je Jacobijeva matrika preslikave } G,$$

$$\rho(A) = \max\{|\lambda| \mid \lambda \text{ je lastna vrednost } A\} \text{ je spektralni radij.}$$

Potem za vsak $x^{(0)} \in \Omega$ zaporedje $x^{(r+1)} = G(x^{(r)})$ konvergira k negibni točki funkcije G , ki je edina negibna točka G na Ω .

Opomba 4.2. TODO Za vsak $\varepsilon > 0$ obstaja matrična norma (za dano matriko A), da je

$$\rho(A) \leq A \leq \rho(A) + \varepsilon.$$

Če je $\alpha = G(\alpha)$ in $\rho(J_G(\alpha)) < 1$, je α privlačna negibna točka. Posledično za $x^{(0)}$ dovolj blizu α bo $\lim_{r \rightarrow \infty} x^{(r)} = \alpha$ za $x^{(r+1)} = G(x^{(r)})$.

4.1 Newtonova metoda

Ideja. Naj bo $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$ dvakrat zvezno odvedljiva v okolici α , kjer $F(\alpha) = 0$. Naj bo $x^{(r)}$ približek za α . Iščemo popravek $\Delta x^{(r)}$, da bo

$$F(x^{(r)} + \Delta x^{(r)}) = 0.$$

Računamo

$$\begin{aligned} 0 &= F(x^{(r)} + \Delta x^{(r)}) = F(x^{(r)}) + J_F(x^{(r)}) \cdot \Delta x^{(r)} + \underbrace{o(\|\Delta x^{(r)}\|^2)}_{\text{zanemarimo}} \\ &\Rightarrow J_F(x^{(r)}) \Delta x^{(r)} \approx -F(x^{(r)}) \\ &\Rightarrow x^{(r+1)} = x^{(r)} - J_F^{-1}(x^{(r)}) \cdot F(x^{(r)}) \end{aligned}$$

Torej iteracijska funkcija je $G(x) = x - J_F^{-1}(x^{(r)}) \cdot F(x^{(r)})$.

Opomba 4.3. Če je α enostavna ničla, je $\det(J_F(\alpha)) \neq 0$.

Algorithm 7: Newtonova metoda

Data: $F : \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^n$, $x_0 \in \Omega$,

Result: $c \in \Omega$, $F(c) = 0$

for $r = 1$ **to** ∞ **do**

solve $J_F(x^{(r)}) \cdot \Delta x^{(r)} = -F(x^{(r)})$
 $x^{(r+1)} \leftarrow x^{(r)} + \Delta x^{(r)}$

end

Opomba 4.4.

- Ne množimo z inverzom, ampak rešimo sistem linearnih enačb.
- Metoda ima kvadratično konvergenco v bližini enostavnih ničel.

Težava z Newtonovo metodo je, da lahko zelo zahtevna, saj

- V vsakem korak potrebujemo $n \times n$ matriko $J_F(x^{(r)})$ in
- vsakič nov LU razcep za $J_F(x^{(r)})$.

4.2 Kvazi Newtonove metode

Ideja. Namesto matrike $J_F(x^{(r)})$ uporabimo njen približek.

Algorithm 8: Kvazi Newtonova metoda

Data: $F : \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^n$, $B_0 \in \mathbb{R}^{n \times n}$, $x_0 \in \Omega$

Result: $c \in \Omega$, $F(c) = 0$

for $r = 1$ **to** ∞ **do**

solve $B_r \cdot \Delta x^{(r)} = -F(x^{(r)})$
 $x^{(r+1)} \leftarrow x^{(r)} + \Delta x^{(r)}$
 update B_r to B_{r+1}

end

Broydenova metoda

Najbolj znana je *Broydenova metoda*. Pri tej metodi določimo B_{r+1} tako, da zadošča, t.i. *sekantnemu pogoju*:

$$B_{r+1} (x^{(r+1)} - x^{(r)}) = F(x^{(r+1)}) - F(x^{(r)}).$$

Pri čemer je $B_{r+1} = B_r + \Delta B_r$ in ima med vsemi možnimi ΔB_r minimalno normo $\|\Delta B_r\|_2$.

Opomba 4.5. Še bolj pomembno je, da ima ΔB_r minimalen rang 1.

Dobimo, da

$$\begin{aligned} (B_r + \Delta B_r) \Delta x^{(r)} &= F(x^{(r+1)}) - F(x^{(r)}), \quad B_r \Delta x^{(r)} = -F(x^{(r)}) \\ \Rightarrow \Delta B_r \Delta x^{(r)} &= F(x^{(r+1)}). \end{aligned}$$

Lema 4.6. Za dana neničelna vektorja $u, v \in \mathbb{R}^n$ je matrika A z minimalno normo $\|\cdot\|_2$, za katero velja $Au = v$, enaka

$$A = \frac{vu^T}{\|u\|_2^2}.$$

Dokaz. **TODO**

□

Algorithm 9: Broydenova metoda

Data: $F : \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^n$, $x_0 \in \Omega$

Result: $c \in \Omega$, $F(c) = 0$

$B_0 \leftarrow J_F(x^{(0)})$

for $r = 1$ **to** ∞ **do**

 solve $B_r \cdot \Delta x^{(r)} = -F(x^{(r)})$

$x^{(r+1)} \leftarrow x^{(r)} + \Delta x^{(r)}$

$B_{r+1} = B_r + \frac{F(x^{(r+1)}) \cdot (\Delta x^{(r)})^T}{\|\Delta x^{(r)}\|_2^2}$

end

Trditev 4.7 (Sherman-Morrisonova formula). **TODO**

$$(A + uv^T)^{-1} = A^{-1} - \frac{(A^{-1}u)(v^T A^{-1})}{1 + v^T A^{-1}u}$$

Opomba 4.8. Sistem $B_r \cdot \Delta x^{(r)} = -F(x^{(r)})$ lahko rešimo v $O(n^2)$ z uporabo Sherman-Morrisonove formule. Sicer ta ni numerično stabilna.

5 Linearni problemi najmanjših kvadratov

5.1 Uvod

Imamo matriko $A \in \mathbb{R}^{m \times n}$, $m > n$, $b \in \mathbb{R}^m$. Iščemo $x \in \mathbb{R}^n$, ki minimizira $\|Ax - b\|_2$.

Če je $m > n$, je sistem $Ax = b$ *predoločen* (več enačb kot neznank). Razen izjemoma (če je $b \in \text{im}A$) tak sistem nima rešitve.

Izrek 5.1. Če je $A \in \mathbb{R}^{m \times n}$, $m \geq n$, $\text{rang}A = n$, potem je $x \in \mathbb{R}^n$, ki za dani $b \in \mathbb{R}^m$ minimizira $\|Ax - b\|_2$, rešitev normalnega sistema $A^T Ax = A^T b$.

Matrika $A^T A$ je *Grammova matrika*.

Predoločen sistem lahko rešimo:

1. $B = A^T A$, $c = A^T b$,
2. $B = VV^T$,
3. $Vy = c$
4. $V^T x = y$

Matrika

$$\begin{bmatrix} 1 & x_1 & \dots & x_1^{n-1} \\ \vdots & & & \\ 1 & x_n & \dots & x_n^{n-1} \end{bmatrix}$$

je *Vandermondova matrika*.

5.2 QR razcep

Izrek 5.2. Naj bo $A \in \mathbb{R}^{m \times n}$, $m \geq n$, $\text{rang}A = n$. Potem obstaja enoličen razcep $A = QR$, kjer je $Q \in \mathbb{R}^{m \times n}$ matrika z ortonormiranimi stolpci ($Q^T Q = I_n$) in $R \in \mathbb{R}^{n \times n}$ zgornja trikotna matrika s pozitivnimi diagonalnimi elementi ($r_{ii} > 0$) za $i \in [n]$.

Algorithm 10: QR razcep

Data: $A \in \mathbb{R}^{m \times n}$

Result: $Q \in \mathbb{R}^{m \times n}$, $R \in \mathbb{R}^{n \times n}$

```

for  $k = 1 : n$  do
     $q_k \leftarrow a_k$ 
    for  $i = 1 : k - 1$  do
         $r_{ik} \leftarrow q_i^T a_k$ 
         $q_k \leftarrow q_k - r_{ik} q_i$ 
    end
     $r_{kk} \leftarrow \|q_k\|_2$ 
     $q_k \leftarrow q_k / r_{kk}$ 
end

```

To je *klasična Gram-Schmidtova ortogonalizacija*.

Obstaja tudi *modificirana Gram-Schmidtova ortogonalizacija*:

Algorithm 11: QR razcep (MGS)

Data: $A \in \mathbb{R}^{m \times n}$

Result: $Q \in \mathbb{R}^{m \times n}$, $R \in \mathbb{R}^{n \times n}$

```

for  $k = 1 : n$  do
     $q_k \leftarrow a_k$ 
    for  $i = 1 : k - 1$  do
         $r_{ik} \leftarrow q_i^T q_k$ 
         $q_k \leftarrow q_k - r_{ik} q_i$ 
    end
     $r_{kk} \leftarrow \|q_k\|_2$ 
     $q_k \leftarrow q_k / r_{kk}$ 
end
  
```

Preprost način reševanja:

1. $[Q, R] = \text{mgs}(A)$;
2. Reši $Rx = Q^T b$.

Boljši način reševanja:

1. Izračunamo QR razcep matrike $\begin{bmatrix} A & b \end{bmatrix}$:

$$\begin{bmatrix} A & b \end{bmatrix} = \begin{bmatrix} Q & q_{m+1} \end{bmatrix} \cdot \begin{bmatrix} R & z \\ 0 & \rho \end{bmatrix};$$

2. Reši $Rx = z$.

5.3 Givensove rotacije

Naj bo $A \in \mathbb{R}^{m \times n}$, $m \geq n$, $\text{rang} A = n$. Vemo, da obstaja QR razcep $A = QR$.

Poznamo tudi razširjeni QR razcep: $A = \tilde{Q}\tilde{R}$, kjer je $\tilde{Q} \in \mathbb{R}^{m \times m}$ ortogonalna, $\tilde{R} \in \mathbb{R}^{m \times n}$ zgornja trapezna (vsi elementi pod glavno diagonalo so enaki 0).

Prvih n stolpcev matrike \tilde{Q} in zgornji kvadrat matrike \tilde{R} tvori QR razcep matrike A . Minimum bo dosežen, ko $Rx = Q^T b$.

Navadno rotacijo v ravnini posplošimo na rotacijo v ravnini (i, k) v \mathbb{R}^n . Označimo z $c = \cos \varphi$ in $s = \sin \varphi$. Dobimo ortogonalno matriko, ki je enaka identiteti povsod razen v i -ti in k -ti vrstici, kjer je

$$R_{ik}^T([i \ k], [i \ k]) = \begin{bmatrix} c & s \\ -s & c \end{bmatrix}.$$

Matriko R_{ik}^T imenujemo *Givensova rotacija*.

Algoritem za splošno matriko velikosti $m \times n$, $m \geq n$, je zapisan v algoritmu 12. Če QR razcep računamo zato, da bomo rešili predoločen sistem $Ax = b$, matrike Q ni potrebno izračunati. Namesto tega v vsakem koraku z rotacijo R_{jk}^T pomnožimo vektor b , na koncu iz produkta $\tilde{Q}^T b$ pobremo prvih n elementov in rešimo sistem $Rx = Q^T b$.

Opomba 5.3. Algoritem 12 matriko A prepiše v matriko \tilde{R} .

Algorithm 12: QR razcep (Givensove rotacije)

Data: $A \in \mathbb{R}^{m \times n}$

Result: $\tilde{Q} \in \mathbb{R}^{m \times m}$, $\tilde{R} \in \mathbb{R}^{n \times n}$

```

 $\tilde{Q} \leftarrow I_m$  /* če potrebujemo matriko  $\tilde{Q}$  */
for  $j = 1 : n$  do
    for  $k = j + 1 : m$  do
         $r \leftarrow \sqrt{a_{jj}^2 + a_{kj}^2}$ 
        if  $r > 0$  then
             $c \leftarrow a_{jj}/r$ 
             $s \leftarrow a_{kj}/r$ 
             $A([j \ k], j : n) \leftarrow \begin{bmatrix} c & s \\ -s & c \end{bmatrix} A([j \ k], j : n)$ 
             $b([j \ k]) \leftarrow \begin{bmatrix} c & s \\ -s & c \end{bmatrix} b([j \ k])$  /* če rešujemo sistem  $Ax = b$  */
             $\tilde{Q}(1 : m, [j \ k]) \leftarrow \tilde{Q}(1 : m, [j \ k]) \begin{bmatrix} c & -s \\ s & c \end{bmatrix}$  /* če potrebujemo  $\tilde{Q}$  */
        end
    end
end
end

```

5.4 Householderjeva zrcaljenja

Za neničelen vektor $w \in \mathbb{R}^n$ definiramo matriko

$$P = I - \frac{2}{w^T w} w w^T.$$

Matriko P imenujemo *Householderjevo zrcaljenje*.

Množenje vektorja x z zrcaljenjem P lahko izvedemo tako, da izračunamo

$$Px = x - \frac{1}{\mu} (w^T x) w,$$

kjer je $\mu = \frac{1}{2} \|w\|_2^2$.

Algorithm 13: QR razcep (Householderjeva zrcaljenja)

Data: $A \in \mathbb{R}^{m \times n}$

Result: $\tilde{Q} \in \mathbb{R}^{m \times m}$, $\tilde{R} \in \mathbb{R}^{n \times n}$

$\tilde{Q} \leftarrow I_m$ /* če potrebujemo matriko \tilde{Q} */

for $i = 1 : \min(n, m - 1)$ **do**

določi $w_i \in \mathbb{R}^{m-i+1}$, ki prezrcali $A(i : m, i)$ v $\pm k e_1 \in \mathbb{R}^{m-i+1}$

$A(i : m, i : n) \leftarrow P_i A(i : m, i : n)$

$b(i : m) \leftarrow P_i b(i : m)$

/* če rešujemo sistem $Ax = b$ */

$\tilde{Q}(1 : m, i : m) = \tilde{Q}(1 : m, i : m) P_i$

/* če potrebujemo matriko \tilde{Q} */

end

6 Problemi lastnih vrednosti

Naj bo $A \in \mathbb{R}^{n \times n}$. Iščemo lastne vrednosti in lastne vektorje.

Izrek 6.1. Za vsako matriko $A \in \mathbb{R}^{n \times n}$ obstajata unitarna matrika $U \in \mathbb{C}^{n \times n}$ in zgornja trikotna $S \in \mathbb{C}^{n \times n}$, da je

$$A = USU^H.$$

To je *Schurova forma*.

Izrek 6.2. Če je $A \in \mathbb{R}^{n \times n}$, obstajata ortogonalna matrika $Q \in \mathbb{R}^{n \times n}$ in kvazi zgornje trikotna (na diagonalni so lahko 2×2 bloki) matrika $R \in \mathbb{R}^{n \times n}$, da je $A = QRQ^T$.

6.1 Potenčna metoda

Naj bo $A \in \mathbb{C}^{n \times n}$, $z_0 \in \mathbb{C}^n$. Definiramo zaporedje

$$z_{k+1} = \frac{Az_k}{\|Az_k\|}. \quad (1)$$

Izrek 6.3. Naj bo λ_1 dominantna lastna vrednost matrike $A \in \mathbb{C}^{n \times n}$, torej

$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|.$$

Za naključno izbran normiran vektor $z_0 \in \mathbb{C}^n$ zaporedje vektorjev z_k izračunanih po predpisu 1 po smeri konvergira proti lastnemu vektorju za λ_1 .

Kaj je ustrezen zaustavitveni kriterij?

Denimo, da imamo približek x za lastni vektor in iščemo lastno vrednost. Najboljši približek je $\lambda \in \mathbb{C}$, ki minimizira

$$\|Ax - \lambda x\|_2.$$

Rešitev je (iščemo rešitev predločenega sistema $x\lambda = Ax$ za λ) *Rayleighov kvocient*

$$\rho(x, A) := \frac{x^H Ax}{x^H x},$$

ki je definiran za $x \neq 0$.

Primeren zaustavitveni kriterij za potenčno metodo je

$$\|Az_k - \rho(z_k, A)z_k\|_2 < \epsilon.$$

Denimo, da smo s potenčno metodo izračunali lastno vrednost λ_1 s pripadajočim normiranim lastnim vektorjem x_1 . Za izračun drugih lastnih parov lahko uporabimo potenčno metodo na reducirani matriki. Dve možnosti redukciji sta:

1. *Householderjeva redukcija*. Z uporabo Householderjeva zrcaljenja poiščemo unitarno matriko U , da je $x_1 = Ue_1$. Potem ima matrika $B = U^H AU$ obliko

$$B = \begin{bmatrix} \lambda_1 & b^T \\ 0 & C \end{bmatrix}.$$

Preostale lastne vrednosti matrike A se ujemajo z lastnimi vrednostmi matrike C .

Opomba 6.4. V potenčni metodi dovolj, da znamo izračunati produkt Cw za vektor $w \in \mathbb{C}^{n-1}$. Pri tem si pomagamo z zvezo

$$U^H AU \begin{bmatrix} 0 \\ w \end{bmatrix} = \begin{bmatrix} b^T w \\ Cw \end{bmatrix}$$

2. *Hotellingova redukcija* v primeru simetrične matrike A . Definiramo

$$B = A - \lambda_1 x_1 x_1^T.$$

Če uporabimo potenčno metodo na matriki B , dobimo drugo dominantno lastno vrednost matrike A .

Opomba 6.5. Matriko B ni potrebno eksplicitno izračunati. Dovolj, da uporabimo zvezo

$$Bz = Az - \lambda_1 (x_1^T z) x_1.$$

Algorithm 14: Potenčna metoda

Data: $A \in \mathbb{C}^{n \times n}$, $z_0 \in \mathbb{C}^n$, $|z_0| = 1$, $\varepsilon > 0$

Result: λ_1

$y_1 \leftarrow Az_0$

$\rho_0 \leftarrow z_0^H y_1$

$k \leftarrow 0$

while $\|y_{k+1} - \rho_k z_k\|_2 \geq \varepsilon$ **do**

$k \leftarrow k + 1$

$z_k \leftarrow y_k / \|y_k\|_2$

$y_{k+1} \leftarrow Az_k$

$\rho_k \leftarrow z_k^H y_{k+1}$

end

Če iščemo po absolutni vrednosti najmanjšo lastno vrednost nesingularne matrike A , uporabimo potenčno metodo na A^{-1} . V algoritmu namesto produkta $y_{k+1} = A^{-1}z_k$ rešimo sistem $Ay_{k+1} = z_k$.

Opomba 6.6. Sistem $Ay_{k+1} = z_k$ lahko rešimo s pomočjo LU razcepa, ki ga dovolj izračunati le enkrat.

6.2 Inverzna iteracija

Denimo, da smo izračunali približek za lastno vrednost in potrebujemo še lastni vektor. Tu si lahko pomagamo z *inverzno iteracijo*:

Algorithm 15: Potenčna metoda

Data: $A \in \mathbb{C}^{n \times n}$, približek za lastno vrednost σ , $z_0 \in \mathbb{C}^n$, $|z_0| = 1$

Result: $z \in \mathbb{C}^n$, $Az \approx \sigma z$

for $k = 0 : \infty$ **do**

 reši sistem $(A - \sigma I)y_{k+1} = z_k$
 $z_{k+1} = y_{k+1} / \|y_{k+1}\|$

end

Opomba 6.7.

- Inverzna iteracija je potenčna metoda za matriko $(A - \sigma I)^{-1}$.
- V praksi potrebujemo le en do dva koraka inverzne iteracije, da iz poljubnega začetnega vektorja izračunamo pripadajoči lastni vektor.

6.3 Ortogonalna iteracija

Definicija 6.8. Podprostor $U \leq \mathbb{C}^n$ je invarianten za matriko $A \in \mathbb{C}^{n \times n}$, če je

$$\forall x \in U. Ax \in U.$$

Naj bo $X = \begin{bmatrix} X_1 & X_2 \end{bmatrix}$ nesingularna in $B = X^{-1}AX = \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix}$.

Stolpci X razpenjajo invariantni podprostor za $A \Leftrightarrow B_{21} = 0$. Lastne vrednosti A so unija lastnih vrednosti B_{11} in B_{22} .

Naj za lastne vrednosti A velja:

$$|\lambda_1| \geq \dots \geq |\lambda_p| > |\lambda_{p+1}| \geq \dots \geq |\lambda_n|. \quad (2)$$

Invariantni podprostor X_1 dimenzije p , ki ustreza lastnim vrednostim $\lambda_1, \dots, \lambda_p$, ke potem *dominanti* invariantni podprostor dimenzije p .

Algorithm 16: Ortogonalna iteracija

Data: $A \in \mathbb{C}^{n \times n}$, $Z_0 \in \mathbb{C}^{n \times p}$, $p \leq n$ z ON stolpci

Result: $Z \in \mathbb{C}^{n \times p}$

for $k = 0 : \infty$ **do**

$Y_{k+1} \leftarrow AZ_k$
 izračunaj QR razcep $Y_{k+1} = Q_{k+1}R_{k+1}$
 $Z_{k+1} \leftarrow Q_{k+1}$

end

Z uporabo algoritma 16 na diagonali matrike Z dobimo p največjih lastnih vrednosti.

Lema 6.9. Če velja 2, potem stolpci Z_k za naključno izbrano matriko Z_0 z ON stolpci konvergirajo proti ortogonalni bazi za dominantni invariantni podprostor dimenzije p .

Če velja še $|\lambda_r| > |\lambda_{r+1}|$ za neka $r < p$, potem prvih r stolpcev Z_k konvergira proti ONB za dominantni invariantni podprostor dimenzije r .

Posledica 6.10. Če za lastne vrednosti matrike $A \in \mathbb{C}^{n \times n}$ velja

$$|\lambda_1| > |\lambda_2| > \cdots > |\lambda_n|,$$

potem za naključno matriko $Z_0 \in \mathbb{C}^{n \times n}$ z ON stolpci matrika $Z_k^T A Z_k$ iz ortogonalne iteracije konvergira k Schurovi formi.

6.4 QR iteracija

Algorithm 17: Osnovna verzija QR iteracije

Data: $A \in \mathbb{C}^{n \times n}$

Result: Lastne vrednosti matrike A

$A_0 \leftarrow A$

for $k = 0 : \infty$ **do**

 izračunaj QR razcep $A_k = Q_k R_k$

$A_{k+1} \leftarrow R_k Q_k$

end

Izrek 6.11. Matrika A_k iz QR iteracije je enaka matrike $Z_k^T A Z_k$, kjer je Z_k matrika iz ortogonalne iteracije za A , kjer vzamemo $Z_0 = I$.

Zahtevnost enega koraka zmanjšamo s predhodno redukcijo na zgornjo Hessenbergovo matriko.

6.4.1 Redukcija na Hessenbergovo obliko

Vsak korak osnovne QR iteracije zahteva $O(n^3)$ operacij. Zahtevnost zmanjšamo, če matriko na začetku preoblikujemo v zgornjo Hessenbergovo obliko.

Definicija 6.12. Matrika A je zgornja Hessenbergova, če je $a_{ij} = 0$ za $i > j + 1$.

Trditev 6.13. Če je A zgornja Hessenbergova matrika, se njena oblika med QR iteracijo ohranja.

Realno matriko A lahko z ortogonalno podobnostno transformacijo $Q^T A Q = H$ preoblikujemo v zgornjo Hessenbergovo matriko. Za splošno matriko uporabimo Householderjeva zrcaljenja.

Algorithm 18: Redukcija na zgornjo Hessenbergovo obliko z uporabo zrcaljenj

Data: $A \in \mathbb{C}^{n \times n}$ **Result:** Ortogonalna matrika Q , Hessenbergova matrika H , da $A = Q^T H Q$ $Q \leftarrow I$ /* če potrebujemo matriko Q */**for** $i = 0 : n - 2$ **do** določi $w_i \in \mathbb{R}^{n-i}$ za H. zrcaljenje P_i , ki prezrcali $A(i+1 : n, i)$ v $\pm k e_1$ $A(i+1 : n, i : n) \leftarrow P_i A(i+1 : n, i : n)$ $A(1 : n, i+1 : n) \leftarrow A(1 : n, i+1 : n) P_i$ $Q(i+1 : n, 1 : n) \leftarrow P_i Q(i+1 : n, 1 : n)$ /* če potrebujemo matriko Q */**end**

Definicija 6.14. Zgornja Hessenbergova matrika H velikosti $n \times n$ je *nerazcepna*, če so vsi njeni poddiagonalni elementi $h_{i+1,i}$ za $i = 1, \dots, n-1$ neničelni.

Če je H razcepna, potem problem lastnih vrednosti razpade na dva ali več ločenih problemov. Zato lahko predpostavimo, da je H nerazcepna.

V praksi proglasimo $h_{i+1,i}$ za dovolj majhnega, ko je

$$|h_{i,i-1}| < \varepsilon(|h_{i-1,i-1}| + |h_{ii}|).$$

6.4.2 Premiki

Konvergenco lahko pospešimo z vpeljavo premikov, kot predstavljeno v algoritmu 19

Algorithm 19: QR iteracija s premiki

Data: $A \in \mathbb{C}^{n \times n}$ **Result:** Premaknjena matrika A $A_0 \leftarrow A$ **for** $k = 0 : \infty$ **do** izberi premik σ_k izračunaj QR razcep $A_k - \sigma_k I \leftarrow Q_k R_k$ $A_{k+1} \leftarrow R_k Q_k + \sigma_k I$ **end**

Lema 6.15. Matriki A_k in A_{k+1} pri QR iteraciji s premiki sta ortogonalno podobni.

Za hitro konvergenco moramo za premik σ_k izbrati čim boljši prebližek za lastno vrednost. Kaj če izberemo točno lastno vrednost?

Lema 6.16. Naj bo σ lastna vrednost nerazcepne zgornje Hessenbergove matrike A . Če je QR razcep $A - \sigma I = QR$ in $B = RQ + \sigma I$, potem je $b_{n,n-1} = 0$ in $b_{nn} = \sigma$.

Za premik izberemo čim boljši približek za lastno vrednost matrike A . Uporabljata se naslednji izbiri:

1. *Enojni premik:* za σ_k izberemo $a_{nn}^{(k)} = \rho(e_n, A_k)$. Primeren le za matrike z realnimi lastnimi vrednostmi.

2. *Dvojni oz. Francisov premik*: vzamemo podmatriko

$$A_k(n-1:n, n-1:n) = \begin{bmatrix} a_{n-1,n-1}^{(k)} & a_{n-1,n}^{(k)} \\ a_{n,n-1}^{(k)} & a_{nn}^{(k)} \end{bmatrix},$$

ki ima lastni vrednosti $\sigma_1^{(k)}$ in $\sigma_2^{(k)}$. Sedaj naredimo dva premika v enem koraku:

Algorithm 20: QR iteracija z dvojni premiki

Data: $A \in \mathbb{C}^{n \times n}$

Result: Premaknjena matrika A

$A_0 \leftarrow A$

for $k = 0 : \infty$ **do**

izračunaj QR razcep $A_k - \sigma_1^{(k)} I \leftarrow Q_k R_k$

$A'_k \leftarrow R_k Q_k + \sigma_1^{(k)} I$

izračunaj QR razcep $A'_k - \sigma_2^{(k)} I = Q'_k R'_k$

$A_{k+1} = R'_k Q'_k + \sigma_2^{(k)} I$

end

7 Polinomska interpolacija

7.1 Uvod

Dane so točke $(x_0, y_0), \dots, (x_n, y_n)$, kjer so x_0, \dots, x_n paroma različne. Iščemo funkcijo f , ki *interpolira* te točke, torej

$$\forall i \in \{0, 1, \dots, n\} . f(x_i) = y_i.$$

7.2 Lagrangeva interpolacija

Pri polinomske interpolaciji iščemo polinom stopnje največ n , za katerega velja $p(x_i) = y_i$ za vse $i \in \{0, 1, \dots, n\}$. Tak polinom je *interpolacijski polinom* v točkah (x_i, y_i) . Točke x_0, x_1, \dots, x_n so imenujemo *vozli*.

Če tak polinom iščemo v standardni bazi $1, x, x^2, \dots, x^n$, potem iščemo koeficiente kot rešitve sistema:

$$\begin{bmatrix} 1 & x_0 & x_0^2 & \dots & x_0^n \\ 1 & x_1 & x_1^2 & \dots & x_1^n \\ \vdots & & & & \\ 1 & x_n & x_n^2 & \dots & x_n^n \end{bmatrix} \cdot \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{bmatrix}.$$

To je *Vandermondova matrika*, ki je nesingularna za paroma različne točke x_0, x_1, \dots, x_n . Njena determinanta je $\prod_{0 \leq i < j \leq n} (x_j - x_i)$. Torej obstaja enolična rešitev, torej je interpolacijski polinom enoličen.

Izrek 7.1. Za paroma različne točke x_0, x_1, \dots, x_n in vrednosti y_0, y_1, \dots, y_n obstaja natanko en polinom p stopnje največ n , za katerega velja $p(x_i) = y_i$ za vse $i \in \{0, 1, \dots, n\}$.

Lagrangevi bazni polinomi so polinomi:

$$l_{n,i} = \prod_{j=0, j \neq i}^n \frac{x - x_j}{x_i - x_j}.$$

Te polinomi tvorijo razčlenitev enote in bazo za vse polinome stopnje n ali manj. Ker velja

$$l_{n,i}(x_j) = \delta_{ij},$$

interpolacijski polinom lahko definiramo na naslednji način:

$$p_n(x) := \sum_{k=0}^n y_k l_{n,k}(x).$$

Izrek 7.2. Naj bo f $n+1$ -krat zvezno odvedljiva. Če so x_0, \dots, x_n paroma različne točke in je p interpolacijski polinom za f na x_0, x_1, \dots, x_n , potem velja:

$$f(x) = p(x) + \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega(x),$$

kjer je

$$\omega(x) = (x - x_0)(x - x_1) \cdots (x - x_n) \quad \text{in} \quad \min\{x_0, x_1, \dots, x_n\} < \xi < \max\{x_0, x_1, \dots, x_n\}$$

7.3 Deljene difference

Definicija 7.3. Za paroma različne točke x_0, x_1, \dots, x_k in funkcijo f je *delna difference* $[x_0, x_1, \dots, x_n]f$ vodilni koeficient mx^k interpolacijskega polinoma za f na točkah x_0, x_1, \dots, x_k .

Izrek 7.4. Za paroma različne točke x_0, x_1, \dots, x_n lahko interpolacijski polinom za f zapišemo v obliki:

$$p(x) = [x_0]f + (x - x_0)[x_0, x_1]f + (x - x_0)(x - x_1)[x_0, x_1, x_2]f + \dots + (x - x_0)(x - x_1) \cdots (x - x_{n-1})[x_0, x_1, \dots, x_n]$$

Uporabimo bazo $1, (x - x_0), (x - x_0)(x - x_1), \dots, (x - x_0)(x - x_1) \cdots (x - x_{n-1})$. Tej obliki pravimo *Newtonova oblika interpolacijskega polinoma*.

Lema 7.5. Naj bodo x_0, x_1, \dots, x_n paroma različne točke. potem velja:

1. $[x_0, x_1, \dots, x_n]f$ je simetrična funkcija glede na točke x_0, x_1, \dots, x_n , tj. vrstni red x_0, x_1, \dots, x_n ni pomemben.
2. Deljena difference je linearni funkcional, tj.

$$[x_0, x_1, \dots, x_n](\alpha f + \beta g) = \alpha[x_0, x_1, \dots, x_n]f + \beta[x_0, x_1, \dots, x_n]g.$$

3. $[x_0, x_1, \dots, x_k]f = \frac{[x_0, x_1, \dots, x_k]f - [x_0, x_1, \dots, x_{k-1}]f}{x_k - x_0}$ za $k > 0$, $[x_0]f = f(x_0)$.

Zdaj lahko izračunamo deljene difference po trikotni shemi:

| x_i | $[x_i]f$ | $[\cdot, \cdot]f$ | $[\cdot, \cdot, \cdot]f$ |
|-------|----------|-------------------|--------------------------|
| x_0 | $F(x_0)$ | | |
| x_1 | $F(x_1)$ | $[x_0, x_1]f$ | |
| x_2 | $F(x_2)$ | $[x_0, x_2]f$ | $[x_0, x_1, x_2]f$ |

Opomba 7.6. Velja:

- $[x_0]f = f(x_0)$;
- $[x_0, x_1]f = \frac{[x_1]f - [x_0]f}{x_1 - x_0} = \frac{f(x_1) - f(x_0)}{x_1 - x_0}$. To je smerni koeficient premice skozi $(x_0, f(x_0))$ in $x_1, f(x_1)$.

Opazimo, če je f zvezno odvedljiva, je

$$\lim_{x_1 \rightarrow x_0} [x_0, x_1]f = f'(x_0).$$

Interpolacijski polinom $F(x_0) + \frac{F(x_1) - f(x_0)}{x_1 - x_0}(x - x_0)$ (sekanta) v limiti $x_1 \rightarrow x_0$ postane tangenta $f(x_0) + f'(x_0)(x - x_0)$.

Z uporabo limit lahko definicijo interpolacijskega polinoma razširimo na primere z večkratnimi točkami. Če se točka x_i pojavi m -krat, potem se moreta polinom in f ujemati v x_i in še v prvih $m - 1$ odvodih:

$$p(x_i) = f(x_i), p'(x_i) = f'(x_i), \dots, p^{(m-1)}(x_i) = f^{(m-1)}(x_i).$$

Če dopuščamo tudi ponavljanje točk, za deljene difference velja rekurzivna zveza:

$$[x_0, x_1, \dots, x_k]f = \begin{cases} \frac{f^{(k)}(x_0)}{k!}, & x_0 = x_1 = \dots = x_k, \\ \frac{[x_0, x_1, \dots, x_k]f - [x_0, x_1, \dots, x_{k-1}]f}{x_k - x_0}, & \text{sicer.} \end{cases}$$

Izrek 7.7. Za k -krat zvezno odvedljivo funkcijo f velja:

$$[x_0, x_1, \dots, x_k]f = \int_0^1 dt_1 \int_0^{t_1} dt_2 \dots \int_0^{t_{k+1}} f^{(k)}(\xi_k) dt_k,$$

kjer je

$$\xi_k = t_k(x_k - x_{k-1}) + t_{k-1}(x_{k-1} - x_{k-2}) + \dots + t_1(x_1 - x_0) + x_0.$$

Posledica 7.8. Za k -krat zvezno odvedljivo funkcijo f velja:

$$[x_0, x_1, \dots, x_k]f = \frac{f^{(k)}(\xi)}{k!},$$

ze nek $\min\{x_0, x_1, \dots, x_k\} \leq \xi \leq \max\{x_0, x_1, \dots, x_k\}$.

Lema 7.9. Za funkcijo f in točke x_0, x_1, \dots, x_n in interpolacijski polinom p za f na teh točkah velja:

$$f(x) = p(x) + [x_0, \dots, x_n, x]f \cdot (x - x_0) \dots (x - x_n).$$

Posledica 7.10. Če p interpolira $(n+1)$ -krat zvezno odvedljivo funkcijo f na točkah x_0, x_1, \dots, x_n , potem velja:

$$f(x) = p(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \cdot \omega(x),$$

za neki $\min\{x_0, x_1, \dots, x_n\} \leq \xi \leq \max\{x_0, x_1, \dots, x_n\}$. Pri tem je ξ odvisen od x .